

Segmentación de clientes mediante modelos de clustering de aprendizaje no supervisado.

Por: Sergio Bouchán Catalán



Índice

Objetivo	3
Descripción del conjunto de datos.....	3
Análisis	4
Año de nacimiento.....	4
Nivel educativo.....	5
Estado Civil	5
Ingresos anuales.....	6
Niños y adolescentes en casa.....	7
Fecha de suscripción a la compañía	9
Días desde la última compra.....	9
Gastos	10
Compras.....	12
Visitas a la página web por mes	13
Campañas con ofertas	14
Quejas	14
Relaciones más importantes entre variables.....	15
Ingresos y gasto total	15
Ingresos y total de compras	16
Ingresos y nivel educativo	16
Gasto total y edad	17
Hijos y gasto total	18
Campañas con ofertas y gasto total	18
Visitas y compras en la página web.....	19
Matriz de correlación y conclusiones	19
Modelado	21
Selección y separación de variables	21
Preprocesamiento.....	21
K-Means	21
Clustering Jerárquico	25
DBSCAN	26
Comparativa y selección del mejor modelo	29
Descripción de segmentos y acciones de negocio	29
Conclusiones.....	34

Objetivo

Identificar clientes con características y tendencias similares para agruparlos mediante técnicas de aprendizaje no supervisado (K-Means, Clustering Jerárquico y DBSCAN), proponer estrategias de negocio basadas en los perfiles identificados y responder a la pregunta: ¿Cómo podemos segmentar a nuestros clientes para diseñar estrategias de marketing más efectivas?

Descripción del conjunto de datos

El conjunto cuenta con 29 columnas y 2240 filas. En la tabla 1 se muestra una descripción de las variables contenidas en el dataset [Customer Personality Analysis](#), que contienen información demográfica, socioeconómica y de comportamiento de compra de los clientes de una empresa no especificada.

Tabla 1: Descripción de variables.

Variable	Tipo de variable	Descripción
Year_Birth	Numérica entera	Año de nacimiento del cliente.
Education	Categórica	Nivel educativo del cliente.
Marital_Status	Categórica	Estado civil del cliente.
Income	Numérica decimal	Ingreso anual del cliente.
Kidhome	Numérica entera	Número de niños en casa.
Teenhome	Numérica entera	Número de adolescentes en casa.
DT_Customer	Fecha	Fecha de inscripción con la compañía.
Recency	Numérica entera	Cantidad de días transcurridos desde la última compra.
MntWines		Monto gastado en vino en los últimos 2 años.
MntFruits		Monto gastado en fruta en los últimos 2 años.
MntMeatProducts		Monto gastado en carne en los últimos 2 años.
MntFishProducts		Monto gastado en pescado en los últimos 2 años.
MntSweetProducts		Monto gastado en dulces en los últimos 2 años.
MntGoldProds		Monto gastado en oro en los últimos 2 años.
NumDealsPurchases		Número de compras hechas con descuento.
NumWebPurchases		Número de compras en la página web.
NumCatalogPurchases		Número de compras por catálogo.
NumStorePurchases		Número de compras hechas en la tienda.
NumWebVisitsMonth		Número de visitas a la página web el último mes.
AcceptedCmp1-5	Numérica binaria	5 columnas, una para cada campaña de ofertas: contiene el valor 1 si el cliente aceptó la oferta de la campaña 0 si no.
Response		1 si el cliente aceptó la oferta de la última campaña, 0 si no.
Complain		1 si el cliente ha presentado una queja en los últimos 2 años, 0 si no.

En la tabla 1 no se incluyen las columnas “Z_CostContact” y “Z_Revenue” ya que tienen los mismo valores en cada fila, por lo tanto, no aportan información útil para la segmentación de clientes y por ello, fueron eliminadas del conjunto de datos. La columna ID también fue eliminada porque al ser un identificador único para cada cliente no resulta de utilidad para este proyecto.

Análisis

Año de nacimiento

La primer variable analizada fue el año de nacimiento de los clientes, en el boxplot de la figura 1 inmediatamente se encuentran 3 datos atípicos correspondientes a los años 1893, 1899 y 1900, se analizaron particularmente estos casos y aunque no presentaban comportamientos fuera de lo común, se decidió eliminarlos, debido a que probablemente son de clientes fallecidos que no fueron eliminados del registro. Posteriormente, se creó la columna edad restando el año actual menos el año de nacimiento de cada cliente; se identificó que la edad del cliente más joven es 30 años y la del mayor 86 años. Con base en el histograma mostrado en la figura 2, se determina que la mayoría de los clientes tienen cerca de los 50 años y se puede observar que son pocos los clientes jóvenes, menores a 40 años los que parecen comprar en esta empresa. Tras eliminar los datos erróneos del año de nacimiento, parece que no se presentan valores extremos en esta variable.




Figura 1: Boxplot del año de nacimiento de los clientes.




Figura 2: Histograma de la edad de los clientes.

Nivel educativo

Se encontraron 5 categorías, Doctorado, Maestría, Posgrado, Licenciatura y Educación Básica. En la figura 3 se muestran un gráfico de barras con los porcentajes de clientes correspondientes a cada nivel educativo; se observa que prácticamente la mitad de los consumidores tienen estudios de nivel licenciatura, mientras que solo el 2.41% se quedó en el nivel básico.




Figura 3: Clientes y niveles educativos.

Estado Civil

Se presentan 5 estados civiles normales en los datos, casado, en unión libre, soltero, divorciado, viudo y algunos estados con inconsistencias en la forma en la que están nombrados, pero que hacen referencia a la soltería, por ende, fueron agrupados dentro de este último estado civil, quedando así, la mayoría de los clientes como casados (38.62%) y tan solo el 3.44% como viudos. En la figura 4 se muestra el gráfico de pastel de estos datos.




Figura 4: Porcentajes del estado civil de los clientes.

Ingresos anuales

En esta variable se encontraron datos faltantes, de 2240 datos hay 24 faltantes (1.07%), una cantidad muy pequeña, pero importante, ya que, muchos de los hábitos de compra de los clientes pueden estar relacionados a sus ingresos, por lo tanto, se realizó un boxplot de esta variable (figura 5) para determinar cuál sería el mejor método de imputación para los datos faltantes; en la figura 5 se puede observar que hay algunos valores atípicos de ingresos considerablemente más altos que los de la mayoría de los clientes (siendo el ingreso más alto de \$666,666.00), debido a esto, la mediana se consideraría una medida de tendencia central más representativa que el promedio, por lo que, será utilizada para imputar los valores faltantes de la variable de ingresos anuales en la etapa del preprocesamiento para los modelos de aprendizaje no supervisado.

En la figura 6 se muestra el histograma de esta variable, excluyendo (únicamente en su visualización) al cliente con el ingreso más alto, con el fin de facilitar la interpretación del gráfico; se observa que la mayor concentración de clientes se encuentra aproximadamente entre \$30,000 y \$80,000 unidades monetarias de ingreso anual, aparecen muy poco registros de personas con ingresos mayores a los \$90,000 anuales y también parecen ser pocas las personas con ingresos menores a los \$20,000.




Figura 5: Boxplot del ingreso de los clientes.




Figura 6: Histograma del ingreso anual.

Niños y adolescentes en casa

La variable “*Kidhome*” corresponde a la cantidad de hijos pequeños (niños) que tienen los clientes, 0, 1 o 2 niños, en la figura 7 se muestra que el 57.71% de los clientes no tiene niños pequeños en casa y solo el 2.15% tiene 2 niños.




Figura 7: Gráfico de barras – Cantidad de niños en casa.

Al igual que con los niños, la mayoría de los clientes no tienen ningún hijo adolescente en casa (51.68%), el 46% tiene solo 1 hijo adolescente y solo el 2.32% de los clientes tienen 2 hijos adolescentes. Esto se observa en la figura 8.




Figura 8: Gráfico de barras – Cantidad de adolescentes en casa.

Se decidió juntar las 2 variables en una sola que representara la cantidad total de hijos de los clientes, para simplificar la información familiar en una única característica más fácil de interpretar y potencialmente más relevante para identificar patrones de consumo durante el proceso de segmentación. En la figura 9 se observa que la mitad de los clientes tienen 1 hijo, mientras que solo el 2.37% tienen 3 hijos en total.




Figura 9: Gráfico de barras – Cantidad de hijos en casa.

Fecha de suscripción a la compañía

Esta variable representa la fecha en la que los clientes se suscribieron a la membresía de la tienda, para un mejor manejo de la variable se agrupó por año y como se muestra en la figura 10, solo hubo 3 periodos de inscripción, del 2012 al 2014, siendo el 2013 el año en el que más clientes adquirieron una membresía (53.06% de los clientes).

Periodo de inicio de la suscripción de los clientes




Figura 10: Gráfico de pastel – inicio de la suscripción.

Días desde la última compra

Esta variable indica el tiempo en días transcurrido desde que los clientes hicieron su última compra, el valor mínimo es de 0 (la compra más reciente) y el mayor de 99 (más de 3 meses sin compras); esta columna es importante porque permite distinguir a los clientes activos. En la figura 11 se observa que la distribución de la variable es bastante uniforme, no existen picos muy grandes o muy pequeños que pudieran ser tomados como valores atípicos, prácticamente hay clientes en todo el rango de días presentados.




Figura 11: Distribución de los días pasados desde la última compra de los clientes.

Gastos

Se realizó un resumen estadístico de las variables relacionadas con la cantidad de dinero que gastan los clientes en determinados productos, los resultados se muestran en la tabla 2:

Tabla 2: Resumen estadístico de gastos.

	Vino	Frutas	Carne	Pescado	Dulces	Oro
media	304.00	26.27	166.92	37.52	27.07	43.97
STD	336.57	39.72	225.66	54.64	41.29	52.05
min	0.00	0.00	0.00	0.00	0.00	0.00
25%	24.00	1.00	16.00	3.00	1.00	9.00
50%	174.00	8.00	67.00	12.00	8.00	24.00
75%	504.00	33.00	232.00	50.00	33.00	56.00
máx	1493.00	199.00	1725.00	259.00	263.00	362.00

En la figura 12 se presentan histogramas de cada una de las variables. De manera general se observa que se presentan distribuciones fuertemente asimétricas hacia la derecha, en todas ellas, la mayoría de los clientes registra gastos bajos, mientras que un grupo reducido concentra valores considerablemente mayores.




Figura 12: Distribución de los gastos por producto.

En la figura 13 se muestra un boxplot de estas mismas variables; se encontraron diferencias importantes en la distribución del gasto entre categorías de productos. Las categorías Vinos y Carne presentan la mayor dispersión y concentran los valores de gasto más elevados, mientras que el resto de las categorías muestran distribuciones más compactas con medianas considerablemente menores. En todas las categorías se identifican valores atípicos, pero no se consideran errores de captura, sino posibles clientes con patrones de consumo específicos que resultan de interés para el proceso de segmentación.




Figura 13: Boxplot de los gastos por producto.

Se creó una variable que engloba la suma del gasto realizado en las distintas categorías de productos (vinos, frutas, carne, pescados, dulces y productos de oro) para obtener el gasto total; esta variable resume el valor monetario total de las compras realizadas por cada cliente, proporcionando una medida integral de su nivel de consumo y tener un indicador relevante para identificar clientes de alto valor y facilitar la interpretación de los segmentos obtenidos mediante técnicas de clustering. En la figura 14 se muestra su histograma que sigue la misma tendencia de los gastos por producto individual: una distribución asimétrica hacia la derecha, donde la mayoría de los clientes registra niveles de gasto bajos o moderados, mientras que un grupo reducido concentra gastos significativamente superiores.




Figura 14: Histograma de los gastos por producto.

Compras

En la figura 15 se muestran los histogramas de la cantidad de compras realizadas en diferentes medios; se observa una tendencia similar a los gastos de los clientes, ya que, la mayoría de los clientes realizan pocas compras, siendo la tienda física el medio más constante.




Figura 15: Distribución de las compras realizadas por diferentes medios.

En el boxplot de la figura 16 se observa que en las compras en tienda no hay valores atípicos, mientras que, en el resto de los medios, el tamaño de las cajas sugiere que la mayoría de los clientes realiza pocas compras y solo unos cuantos parecen comprar una cantidad considerablemente mayor.




Figura 16: Boxplot de tipos de compra.

Se sumaron las compras de cada uno de los medios para crear la variables de compras totales, la cual, de acuerdo con el gráfico de la figura 17, presenta una distribución más variada y se observa que ya no son tantos los clientes que realizan muy pocas compras, ahora se muestra un distribución que sugiere distintos niveles de actividad comercial entre los clientes, una característica que podría contribuir a la identificación de los segmentos cuando se realice el clustering.




Figura 17: Histograma del total de compras.

Visitas a la página web por mes

En la figura 18 se muestra la distribución de las visitas mensuales a la página web, se observa que la mediana está alrededor de las 6 visitas al mes; el 50% de los clientes realiza aproximadamente entre 3 y 7 visitas y hay pocos valores atípicos, lo que sugiere que es una variable bastante estable.




Figura 18: Boxplot de visitas mensuales a la página web.

Campañas con ofertas

La compañía ha ofrecido 6 campañas de promociones; se creó una variable que representa el número total de campañas de ofertas aceptadas por cada cliente para resumir el historial de respuesta a campañas en una única característica cuantitativa, facilitando la interpretación del comportamiento del cliente y reduciendo la redundancia entre múltiples variables binarias. En la figura 19 se observa que el 72.82% de los clientes no ha aceptado ninguna campaña y ningún cliente ha podido aceptarlas todas.




Figura 19: Gráfico de barras de campañas de ofertas aceptadas.

Quejas

Esta variable solo posee 2 valores, 0 para indicar que un cliente nunca ha puesto una queja y 1 para el caso contrario. En la figura 20 se muestra que el 99.11% de los clientes nunca ha puesto una queja.



Figura 20: Gráfico de pastel de quejas puestas.

Relaciones más importantes entre variables

El análisis de las relaciones entre variables permite comprender cómo interactúan las características de los clientes y su comportamiento de compra; en particular, se busca identificar si factores como los ingresos, la edad, la composición del hogar o la respuesta a campañas de marketing se asocian con el gasto total y la frecuencia de compra. Estas relaciones proporcionan información valiosa para comprender mejor el perfil de los clientes y sirven como fundamento para la posterior construcción e interpretación de los segmentos generados mediante los modelos de aprendizaje no supervisado.

Ingresos y gasto total

En esta sección se buscó identificar si los clientes con mayores ingresos son los que tienen también los mayores gastos, para ello, se calculó la correlación entre estas variables y se obtuvo un resultado de 0.67, lo que corresponde a una correlación moderadamente fuerte, esto significa que en general, conforme aumenta el ingreso anual de los clientes, es más probable que también aumente su gasto total. En la figura 21 se muestra un gráfico de dispersión con una línea de regresión que tiene una tendencia positiva, lo que, reafirma la correlación obtenida, sin embargo, la dispersión observada indica que el ingreso por sí solo no explica el comportamiento de gastos de los clientes, ya que existen datos con niveles de ingreso similares, pero patrones de consumo significativamente diferentes. Esta variabilidad respalda la aplicación de técnicas de clustering para identificar segmentos de clientes con características y hábitos de compra diferenciados. Cabe destacar que se dejó fuera el ingreso más alto (\$666,666) para poder tener una mejor visualización del gráfico.




Figura 21: Gráfico de dispersión con línea de tendencia de los ingresos y los gastos.

Ingresos y total de compras

Los ingresos y el total de compras tienen una correlación de 0.57, una correlación positiva, moderada, que sugiere que generalmente, los clientes con mayores ingresos tienden a realizar un mayor número de compras; sin embargo, la dispersión de los datos mostrada en la figura 22 indica que existen diferencias importantes en la frecuencia de compra entre clientes con ingresos similares y al comparar estos resultados con la relación entre ingresos y gasto total, se aprecia que el ingreso anual presenta una asociación más fuerte con el monto gastado que con la cantidad de compras realizadas.




Figura 22: Gráfico de dispersión con línea de tendencia de los ingresos y compras realizadas.

Ingresos y nivel educativo

El estudio de estas dos variables pretende determinar si existe una diferencia en los ingresos de los clientes según su nivel educativo; el análisis mostró una diferencia clara entre los clientes con educación básica y aquellos con estudios superiores, ya que, como se muestra en la figura 23, los clientes del nivel educativo básico presentan la menor mediana de ingreso y una variabilidad considerablemente menor, en contraste, los clientes con licenciatura, posgrado, maestría y doctorado exhiben distribuciones más solapadas. Estos resultados sugieren que un mayor nivel educativo sí puede asociarse con mayores ingresos, pero después de la licenciatura, las evidencias muestran que no es necesariamente el factor determinante en los ingresos anuales que percibe una persona.




Figura 23: Boxplots del ingreso anual y el nivel educativo de los clientes.

Gasto total y edad

Se identificó una correlación positiva débil (0.11) entre la edad y el gasto total de los clientes y aunque la línea de tendencia de la figura 24 muestra un ligero incremento del gasto conforme aumenta la edad, la amplia dispersión de los datos indica que clientes de edades similares presentan niveles de gasto muy diferentes. Estos resultados sugieren que la edad, por sí sola, no constituye un factor determinante del comportamiento de compra en este conjunto de datos.




Figura 24: Gráfico de dispersión con línea de tendencia de la edad y el gasto total.

Hijos y gasto total

Se identificó una correlación negativa moderada (-0.50) entre el número total de hijos y el gasto total de los clientes. Los hogares sin hijos presentan los mayores niveles de gasto y la mayor variabilidad, mientras que el gasto disminuye conforme aumenta el número de hijos como se observa en la figura 25, una posible explicación sería que los clientes sin hijos disponen de una mayor proporción de ingresos para consumo de productos premium, mientras que los hogares con más hijos podrían priorizar otros tipos de gastos no representados en este conjunto de datos.




Figura 25: Boxplots – Gasto total por cantidad de hijos.

Campañas con ofertas y gasto total

Al analizar estas dos variables se busca saber si los clientes que más gastan son los que más aprovechan las ofertas. Se obtuvo una correlación positiva moderada de 0.46 entre estas variables y los diagramas de caja (figura 26) muestran una tendencia creciente en el gasto conforme aumenta el número de campañas aceptadas, lo que sugiere que los clientes más receptivos a las estrategias de marketing también tienden a generar un mayor valor económico para la empresa.




Figura 26: Boxplots – Gasto total y ofertas aprovechadas.

Visitas y compras en la página web

Para saber si el número de visitas que hace un cliente a la página web se traduce en compras, se calculó la relación entre ambas variables y se obtuvo un resultado de -0.06 , prácticamente nulo, además la elevada dispersión observada en la figura 27 indica que clientes con un número similar de visitas presentan comportamientos de compra muy diferentes; estos resultados sugieren que la frecuencia de visita al sitio web, por sí sola, no constituye un buen predictor de la actividad de compra en línea.




Figura 27: Gráfico de dispersión de visitas a la página web y compras en línea.

Matriz de correlación y conclusiones

Por último, se elaboró una matriz de correlación (ver figura 28) de las variables más importantes y observa que el gasto total presenta una fuerte asociación con el número de compras ($r = 0.75$) y una correlación positiva moderadamente fuerte con el ingreso anual ($r=0.67$). Por otra parte, el número total de hijos muestra una correlación negativa moderada con el gasto ($r = -0.50$), mientras que la edad presenta relaciones débiles con el resto de las variables. Estos resultados indican que el comportamiento de compra está influenciado principalmente por factores económicos y comerciales más que por características demográficas como la edad.

Del análisis realizado se obtienen las siguientes conclusiones:

- Se identificó una correlación positiva moderadamente fuerte entre el ingreso anual y el gasto total ($r = 0.67$), así como una correlación positiva moderada con el número total de compras ($r = 0.57$), por lo que, en general, los clientes con mayores ingresos tienden a realizar compras de mayor valor y con mayor frecuencia.

- La relación más fuerte observada en el análisis corresponde al gasto total y el número de compras ($r = 0.75$), lo que indica que los clientes que realizan más transacciones suelen generar un mayor valor económico para la empresa.
- Se encontró una correlación negativa moderada entre el número total de hijos y el gasto total ($r = -0.50$). Los clientes sin hijos presentan, en promedio, niveles de gasto superiores, mientras que el gasto disminuye conforme aumenta el número de hijos.
- Los clientes que aceptaron un mayor número de campañas presentan un gasto total más elevado ($r = 0.46$), lo que sugiere que la receptividad a las estrategias de marketing puede utilizarse como un indicador del potencial comercial de los clientes.




Figura 28: Matriz de correlación de las variables más importantes.

Este análisis exploratorio permitió identificar las variables con mayor capacidad para describir el comportamiento de los clientes y proporcionó una mejor comprensión de los factores asociados al consumo que serán relevantes al momento de analizar los grupos contruidos por los algoritmos de clustering de aprendizaje no supervisado.

Modelado

Selección y separación de variables

Con base en los resultados del análisis, se seleccionaron las variables de nivel educativo, estado civil, ingreso anual, edad, total de hijos, gasto total, total de compras y campañas de ofertas aceptadas porque mostraron mayor capacidad para describir las características demográficas, económicas y de comportamiento de los clientes, además, se priorizaron las variables derivadas creadas, ya que sintetizan la información de múltiples características originales y reducen la redundancia del conjunto de datos. Posteriormente, las variables fueron separadas en numéricas y categóricas para aplicar el preprocesamiento adecuado antes de entrenar los algoritmos de clustering.

Preprocesamiento

Se tenían valores faltantes en la variable de ingresos, las variables numéricas estaban representadas en escalas diferentes y se tenían variables categóricas que se debían convertir a numéricas, por lo que, antes de pasar a la construcción y entrenamiento de los modelos, dentro de un Pipeline se realizó la imputación de los datos con la mediana, se estandarizaron usando un Standard Scaler y se codificaron las variable categóricas con un One Hot Encoder. A continuación, se presentan los modelos utilizados.

K-Means

K-Means es un algoritmo de aprendizaje no supervisado utilizado para agrupar datos con características similares. El algoritmo divide los datos en un número previamente definido de grupos o clústeres asignando cada observación al centroide más cercano. Para determinar un número adecuado de clústeres en este análisis, se utilizaron el método del codo y *Silhouette Score*.

El método del codo es una técnica utilizada para estimar el número adecuado de clústeres en K-Means. Consiste en entrenar el algoritmo con diferentes números de clústeres y observar cómo cambia la suma de las distancias cuadráticas entre las observaciones y el centroide del clúster al que pertenecen (inercia). Conforme aumenta el número de clústeres, la inercia disminuye y el objetivo es identificar el punto a partir del cual agregar más clústeres ya no reduce significativamente la inercia, formando visualmente un “codo” en la curva como el que se muestra en la figura 29; en la cual se observa que de 1 a 2 clústeres hay una reducción de inercia significativa, mientras que a partir del tercer clúster la disminución comienza a ser más gradual, por lo que 2 o 3 clústeres podrían considerarse candidatos razonables para la segmentación, sin embargo, debido a que el punto de inflexión no es completamente evidente y la interpretación del método del codo puede ser subjetiva, se complementó el análisis mediante el *Silhouette Score*.



Figura 29: Método del codo.

Silhouette Score es una métrica utilizada para evaluar la calidad de una segmentación, considerando tanto la cohesión de las observaciones dentro de su propio clúster como la separación con respecto a los demás clústeres. Su valor se encuentra entre -1 y 1 con valores cercanos a 1 indicando clústeres compactos y bien separados; valores cercanos a 0 sugieren cierto solapamiento entre grupos y valores negativos pueden indicar que algunas observaciones han sido asignadas a un clúster poco adecuado. El mayor *Silhouette Score* se obtuvo utilizando 2 clústeres, con un resultado aproximado de 0.27 (ver figura 30) que, aunque no es un valor muy alto, en conjunto con el método del codo, se justificar la elección de 2 clústeres para segmentar a los clientes.




Figura 30: Gráfica del *Silhouette Score*.

A partir de los resultados obtenidos mediante el método del codo y el Silhouette Score, se seleccionó una configuración de 2 clústeres para el modelo K-Means; el algoritmo fue entrenado utilizando las variables previamente seleccionadas, imputadas, codificadas y estandarizadas para que cada cliente fuera asignado al clúster más cercano. Se detectaron 1243 clientes del tipo 1 y 994 del tipo 0, posteriormente se explicará la interpretación de ambos tipos.

En la figura 31 se muestra un ejemplo de la segmentación realizada con las variables de gasto total e ingreso anual, estas variables fueron seleccionadas para la visualización debido a su relevancia y relación identificada durante el análisis exploratorio. La visualización muestra una diferenciación entre los dos segmentos identificados: el clúster 0 concentra principalmente clientes con niveles de ingreso y gasto más elevados, mientras que el clúster 1 presenta una mayor concentración de clientes con ingresos medios o bajos y niveles de gasto considerablemente menores. También se observa una zona de solapamiento, particularmente entre clientes con ingresos intermedios, este comportamiento es consistente con el Silhouette Score de aproximadamente 0.27, el cual indicaba que, aunque existe una estructura de agrupamiento identificable, los segmentos no se encuentran completamente alejados entre ellos. Se observan clientes con ingresos elevados, pero niveles de gasto reducidos que permanecen en el clúster de menor consumo, lo que, evidencia que la segmentación no está determinada únicamente por el nivel de ingresos, sino por la combinación de las diferentes características utilizadas por el modelo.

Cabe mencionar que todas las variables seleccionadas fueron utilizadas para el proceso, no solo las dos mencionadas anteriormente y que, en este gráfico, para mejorar la visualización, no se incluyó al cliente de mayor ingreso anual, pero sí se mantuvo durante el análisis.




Figura 31: Gráfica de dispersión de la segmentación de clientes considerando el gasto total y el ingreso anual.

Para comprender las características de los segmentos identificados por el algoritmo K-Means, se analizaron las principales variables numéricas de cada clúster mediante medidas descriptivas como la media y debido a la presencia de distribuciones asimétricas y valores atípicos en algunas variables, se consideró también la mediana. En la tabla 3 se muestran los resultados obtenidos de estos cálculos, resaltando los valores mayores en cada categoría

Tabla 3: Promedio y mediana de las variables numéricas y sus grupos.

Variable	Medida	Grupo 0	Grupo 1
Edad (años)	promedio	59.31	55.33
	mediana	59.00	54.00
Ingreso (\$)	promedio	71084.76	37090.45
	mediana	70172.00	36959.00
Total de hijos	promedio	0.57	1.25
	mediana	0.50	1.00
Gasto total (\$)	promedio	1175.26	150.32
	mediana	1120.00	79.00
Total de compras	promedio	21.60	9.49
	mediana	21.00	8.00
Campañas aceptadas	promedio	0.79	0.17
	mediana	0.00	0.00

Los resultados muestran diferencias importantes entre ambos segmentos:

Clúster 0:

- Ingreso bastante superior.
- Niveles de gasto considerablemente más altos.
- Mayor cantidad de compras.
- Menor cantidad de hijos.

Clúster 1:

- Ingreso bastante menor.
- Niveles de gasto considerablemente más bajos (una diferencia de más de \$1000 en promedio).
- Menor cantidad de compras (menos de 10 compras en promedio).
- Menor cantidad de hijos (resaltando lo encontrado en el análisis: más hijos, menos gasto en la tienda).

Con base en estas características, el **clúster 0 puede denominarse como “Clientes de alto valor”**, mientras que el **clúster 1 puede interpretarse como “Clientes de bajo consumo”**.

Los segmentos obtenidos presentan perfiles comercialmente interpretables, sin embargo, el Silhouette Score moderadamente bajo y el solapamiento observado entre los grupos indican que la estructura de los clientes no se encuentra completamente separada. Por ello, los resultados de K-Means serán comparados posteriormente con otros métodos de clustering para evaluar si existen estructuras alternativas que representen mejor los diferentes perfiles de clientes.

Clustering Jerárquico

El clustering jerárquico aglomerativo es un método de aprendizaje no supervisado que construye agrupaciones mediante la unión progresiva de observaciones o grupos similares; inicialmente, cada observación constituye un clúster independiente; posteriormente, en cada iteración se fusionan los grupos más cercanos hasta formar una única agrupación.

La representación gráfica del proceso mediante el cuál el algoritmo fusiona observaciones y grupos según su similitud es el dendrograma. En un dendrograma se busca el tramo vertical más largo donde no ocurren fusiones, porque esto indica que, para unir los grupos existentes en ese nivel, fue necesario aumentar drásticamente la distancia y cortar el dendrograma en este hueco separa los grupos que son naturalmente distintos entre sí. En la figura 32 se observa que la última fusión ocurre en la distancia 87 aproximadamente, la penúltima fusión ocurre alrededor de la distancia 58 y esta parece ser la distancia más grande entre agrupaciones, entonces, al realizar un corte teórico horizontal entre estas dos, se obtienen 2 clústeres, un resultado consistente con el obtenido previamente mediante K-Means, donde el *Silhouette Score* también favoreció una segmentación en dos grupos.




Figura 32: Dendrograma.

Tomando en cuenta el resultado obtenido por el dendrograma, se entrenó el modelo de clustering jerárquico con 2 clústeres y con las mismas variables que el algoritmo anterior. Se obtuvieron 1371 clientes del tipo 0 y 866 del tipo 1. En la tabla 4 se muestra una comparativa entre la cantidad de clientes asignados a cada grupo en ambos modelos analizados hasta el momento. En total, ambos algoritmos coincidieron en la asignación de 1,858 de los 2,237 clientes, aproximadamente el 83.1% de las observaciones; esto sugiere que los dos métodos identifican una estructura general similar en los datos, aunque presentan diferencias en la clasificación de un grupo de clientes con características posiblemente intermedias entre ambos segmentos.

Tabla 4: Comparativa entre modelos – K-Means y Clustering Jerárquico.

Modelo	Clustering Jerárquico		
K-Means	0	1	Total
0	993	1	994
1	378	864	1243
Total	1371	866	2237

En la tabla 5 se muestran los promedios y las medianas de las variables empleadas para entrenar el modelo con los clientes ya separados en ambos clústeres. Se observa que al igual que con el modelo K-Means, se tienen dos perfiles de clientes, el grupo 0 con mayores ingresos, gastos y compras y el grupo 1 con valores más modestos. En general, estos resultados cuentan la misma historia que el algoritmo anterior, identificando a dos grupos de clientes, los de alto valor y los de bajo consumo, sin embargo, en el clustering jerárquico disminuyeron los promedios y medianas de las variables, generando así clústeres menos extremos y asignando una mayor cantidad de clientes al clúster 0, es decir, de acuerdo con este modelo, hay más clientes que pueden ser considerados de alto valor.

Tabla 5: Promedio y mediana de las variables numéricas y sus grupos – Clustering Jerárquico.

Variable	Medida	Grupo 0	Grupo 1
Edad (años)	promedio	59.28	53.64
	mediana	59.00	53.00
Ingreso (\$)	promedio	64020.72	33519.78
	mediana	64758.50	33581.00
Total de hijos	promedio	0.71	1.33
	mediana	1.00	1.00
Gasto total (\$)	promedio	936.87	81.52
	mediana	907.00	57.00
Total de compras	promedio	19.54	7.48
	mediana	20.00	7.00
Campañas aceptadas	promedio	0.62	0.17
	mediana	0.00	0.00

DBSCAN

DBSCAN es un algoritmo de clustering basado en densidad que, a diferencia de K-Means, no requiere especificar previamente el número de clústeres porque identifica regiones con una alta concentración de observaciones y las separa de aquellas con menor densidad. En este algoritmo se necesitan considerar dos situaciones importantes, la primera es, determinar el número mínimo de observaciones necesarias dentro de una región para considerarla lo suficientemente densa como para formar un grupo y la segunda, establecer la distancia máxima que consideraría a dos observaciones como vecinas.

Como punto de partida se utilizaron 5, 10, 25 y 50 observaciones (K) como los valores mínimos requeridos para formar un grupo y se construyeron gráficas de distancia al K vecino (k -distance plot) en las que para cada observación se calculó la distancia con respecto a su K vecino más cercano, se ordenaron estas distancias de menor a mayor y se graficaron con el objetivo de identificar un rango en el la pendiente del gráfico cambia. En la figura 33 se observa que la distancia aumenta gradualmente para la mayor parte de las observaciones y presenta un crecimiento más pronunciado hacia el extremo final, mostrando una región de interés aproximadamente de entre 1.4 y 3.0, por lo que, se tomaron valores dentro y ligeramente fuera de este rango para explorar la combinación de diferentes medidas de distancia y cantidad mínima de observaciones para registrar el número de clústeres encontrados y la cantidad de datos clasificados como ruido de estas distintas combinaciones.




Figura 33: Gráficos de distancia K.

La mayoría de los resultados encontrados entre estas combinaciones identifican un solo grupo, por lo que, esos valores fueron descartados ya que el objetivo del proyecto es la segmentación de los clientes y el tener un solo grupo de clientes no resulta en información útil para esta situación. Otros resultados detectaron varios segmentos, pero tienen una cantidad de ruido bastante alta, por lo que, tampoco fueron considerados para continuar con el proceso, ya que más del 30% de los datos considerados como ruido, sería aislar a clientes que no necesariamente tienen comportamientos atípicos. En la tabla 6 se muestran los resultados que se consideraron apropiados para continuar con el proceso.

Tabla 6: Mejores resultados de las combinaciones de distancia máxima entre vecinos y mínimo de observaciones.

Mínimo de observaciones	Distancia entre vecinos	Grupos formados	Ruido
5	1.40	35	420
	1.48	2	253
10	1.50	2	341

Se analizaron a mayor detalle los modelos creados con las variables mostradas en la tabla anterior, pero ninguna combinación produjo una segmentación adecuada, al tener un mínimo de 5 observaciones y una distancia de 1.40, DBSCAN identificó 35 clústeres, generando una segmentación excesivamente fragmentada con muchos clústeres muy chicos con menos de 10 clientes y tomando en cuenta que la tienda tiene registrados a 2237 clientes, el crear campañas de marketing o personalizar promociones para grupos tan pequeños, no es una estrategia rentable.

En la tabla 7 se muestran los resultados de las combinaciones restantes y como se observa, en realidad DBSCAN no segmentó en dos grupos los datos, ya que, hay una diferencia enorme entre la cantidad de clientes en el grupo 0 comparada con el grupo 1.

Tabla 7: Resultados de las 2 combinaciones restantes.

Mínimo de observaciones	Distancia entre vecinos	Grupo 0	Grupo 1	Ruido
5	1.48	1983	1	253
10	1.50	1888	8	341

En conjunto, los resultados muestran que DBSCAN pasa de generar numerosos grupos pequeños a formar prácticamente una única región densa, sin presentar una solución intermedia estable con pocos clústeres de tamaños interpretables. Por esta razón, **DBSCAN no fue empleado como modelo de segmentación para este conjunto de datos.**

Comparativa y selección del mejor modelo

Una vez evaluados los diferentes métodos de clustering, se realizó una comparación de los resultados obtenidos con K-Means y clustering jerárquico aglomerativo (tabla 8).

Tabla 8: Comparación entre modelos.

Modelo	Clústeres	<i>Silhouette Score</i>	Clientes de alto valor	Clientes de bajo consumo
K-Means	2	0.27	994	1243
Clustering Jerárquico	2	0.20	1371	866

Tanto K-Means como el clustering jerárquico identificaron una estructura general formada por dos segmentos de clientes, además, la comparación de las asignaciones mostró coincidencia para 1,858 de las 2,237 observaciones, aproximadamente el 83.1% de los clientes, lo que proporciona evidencia de que ambos métodos están detectando una estructura subyacente similar, sin embargo, K-Means obtuvo un Silhouette Score ligeramente superior y produjo grupos un poco más equilibrados, por lo tanto, considerando conjuntamente los resultados obtenidos, **K-Means fue seleccionado como el modelo final de segmentación** porque, aunque el Silhouette Score obtenido (≈ 0.27) indica que la separación entre los grupos no es extremadamente pronunciada, fue el modelo que presentó el mejor equilibrio entre calidad de agrupamiento, estabilidad, distribución de clientes e interpretabilidad.

Descripción de segmentos y acciones de negocio

El modelo de K-Means estableció dos grupos, el 0 y el 1. A continuación se enlistan las características de cada uno:

Grupo 0:

- Edad promedio de casi 60 años.
- Ingresos altos, superando en promedio los \$70,000.
- Alto gasto total en la tienda, en promedio superando los \$1,100.
- Mayor cantidad de compras, superando en promedio 20 compras por cliente.
- Ligeramente mayor susceptibilidad a aprovechar las ofertas.

Grupo 1:

- Edad promedio de 53 años, son clientes ligeramente más jóvenes, pero no lo suficiente como para usar la edad como enfoque hacia alguna acción de negocio.
- Ingresos promedio por debajo de los \$40,000.
- Tienen hijos.
- Invierten considerablemente menos en la tienda (promedio de \$150).
- Compran en promedio menos de 10 veces.
- Susceptibilidad a ofertas prácticamente nula.

Debido al mayor ingreso, cantidad de compras y gasto total, el grupo 0 fue catalogado como **Clientes de alto valor**, mientras que el grupo 1 como **Clientes de bajo consumo**.

En la tabla 9 se presenta el gasto promedio y la mediana del gasto de cada grupo en las diferentes categorías de productos que ofrece la tienda; se observa que el grupo de clientes de alto valor gasta más en todos los productos.

Tabla 9: Promedio y mediana de los gastos por tipo de producto y grupo.

Producto	Medida	Grupo 0	Grupo 1
Vino	promedio	593.35	72.61
	mediana	539.00	30.00
Frutas	promedio	50.45	6.94
	mediana	33.50	3.00
Carne	promedio	334.59	32.83
	mediana	265.00	18.00
Pescado	promedio	71.94	10.00
	mediana	52.00	4.00
Dulces	promedio	52.65	6.61
	mediana	36.00	3.00
Oro	promedio	72.27	21.33
	mediana	53.00	12.00

En la figura 34 se presenta la composición porcentual del gasto de cada grupo por tipo de producto, es decir, del gasto total del grupo, qué porcentaje está dirigido a cada tipo de producto. Esta comparativa resulta mucho más interesante y útil, ya que se puede ver que hay en particular un grupo en el que la distribución difiere considerablemente entre ambos grupos, el oro, este producto representa una mayor proporción del gasto total para los clientes de bajo consumo que para los clientes de alto valor.




Figura 34: Distribución de las compras por grupo y producto.

Este análisis por categoría confirmó la existencia de una marcada diferencia en el nivel de consumo entre los segmentos. El clúster 0 presenta medias y medianas de gasto considerablemente superiores en todas las categorías de producto, reforzando su caracterización como el segmento de mayor valor económico.

Sin embargo, al analizar la composición porcentual del gasto, ambos segmentos muestran al vino como su principal categoría, representando aproximadamente la mitad del gasto total de cada grupo, pero los productos de oro adquieren una importancia proporcional considerablemente mayor para los clientes de bajo consumo (14.19% frente a 6.15%). Estos resultados muestran que las diferencias entre los segmentos no se limitan únicamente al volumen total de consumo, sino que también existen variaciones en la composición de su gasto, información que puede ser utilizada para diseñar estrategias comerciales y promociones diferenciadas.

A continuación, se presentan algunas posibles acciones comerciales a tomar en cuenta con base en los resultados obtenidos, destacando que estas propuestas representan hipótesis, su efectividad debería evaluarse posteriormente mediante experimentos controlados, antes de implementarlas de manera generalizada.

Clúster 0 — Clientes de mayor valor:

Como este segmento presenta un gasto elevado y concentra gran parte de su consumo en **vinos (50.5 %)** y **carnes (28.5 %)**, se podrían plantear:

- Programas de fidelización o recompensas por compras.
- Promociones combinadas de **vino + carne**.
- Campañas de retención, ya que perder clientes de este segmento podría representar una mayor pérdida económica.
- Ofertas personalizadas, dado que este grupo también mostró una mayor aceptación histórica de campañas.

El objetivo principal con los clientes de alto valor sería su retención y aumento del valor del cliente.

Clúster 1 — Clientes de menor consumo

- Promociones en **productos de oro**, dado su mayor peso relativo dentro de la canasta del segmento.
- Descuentos o promociones de entrada para incentivar compras adicionales.
- Promociones de oro y/o vino en conjunto con otras categorías de menor participación para intentar realizar **venta cruzada**.
- Campañas enfocadas en aumentar la frecuencia de compra o el ticket promedio.

Se buscaría utilizar una categoría por la que el segmento ya muestra cierta afinidad (los productos de oro y vino) para intentar introducir a los clientes a otros productos.

En la tabla 10 se presenta el promedio y la mediana de la cantidad de compras que realiza cada grupo en los diferentes canales de venta de la compañía y de nuevo, se observa que los clientes de alto valor compran en promedio más sin importar el medio que los clientes de bajo consumo.

Tabla 10: Promedio y mediana de la cantidad de compras por canal y grupo

Canal	Medida	Grupo 0	Grupo 1
Web	promedio	5.84	2.69
	mediana	6.00	2.00
Catálogo	promedio	5.04	0.76
	mediana	5.00	1.00
Tienda	promedio	8.43	3.68
	mediana	8.00	3.00

En la figura 35 se presenta la composición porcentual de las compras de cada grupo por medio de compra, es decir, de las compras totales del grupo, qué porcentaje está dirigido a cada medio de compra. Este análisis de los canales de compra muestra que la tienda física constituye el principal canal de compra para ambos grupos, representando el 43.68% de las compras de los clientes de alto valor y el 51.62% de las compras de los clientes de bajo consumo, sin embargo, se observa una diferencia importante en el uso del catálogo, ya que, este medio representa el 26.09% de las compras de los clientes de alto valor (prácticamente $\frac{1}{4}$ de las compras), frente a únicamente el 10.69% de los clientes de bajo consumo, lo que sugiere que los clientes de bajo consumo prefieren comprar en la tienda física, en algunos casos en línea y muy rara vez por catálogo.




Figura 35: Distribución de las compras por medio y grupo.

A continuación, se presentan algunas posibles acciones comerciales a tomar en cuenta, destacando de nuevo, que estas propuestas representan hipótesis y su efectividad debería evaluarse antes de implementarlas de manera generalizada.

Clúster 0 — Clientes de mayor valor:

Este segmento utiliza los tres canales de forma relativamente equilibrada: tienda 43.68%, web 30.22% y catálogo 26.09%. Por ello, se recomendaría:

- Mantener una estrategia omnicanal, evitando concentrar la comunicación exclusivamente en tienda y el sitio web.
- Aprovechar el catálogo, ya que tiene mucho más peso en este segmento y se podría utilizar para promocionar productos premium, novedades o recompensas.
- Integrar los canales mediante promociones cruzadas, por ejemplo, productos descubiertos en catálogo que puedan adquirirse fácilmente por web o tienda.
- Priorizar estrategias de fidelización y experiencia personalizada, ya que se trata del segmento que genera mayor consumo.

Clúster 1 — Clientes de menor consumo

Este grupo concentra aproximadamente 89.31% de sus compras entre tienda física y web, mientras que el catálogo representa solamente 10.69%. Por lo tanto, se busca:

- Priorizar tienda física y sitio web para promociones dirigidas a este segmento.
- Evitar destinar demasiados recursos a campañas mediante catálogo, dado su menor uso relativo.
- Utilizar promociones web sencillas orientadas a incrementar la frecuencia de compra o el ticket promedio.
- Aprovechar la tienda para estrategias de venta cruzada, especialmente utilizando productos que ya tengan afinidad con el segmento como el oro.
- Facilitar la transición entre tienda y web mediante cupones o promociones utilizables en ambos canales.

A partir de los patrones observados, para los clientes de alto valor podría resultar conveniente mantener una estrategia omnicanal, aprovechando especialmente el mayor uso relativo del catálogo para comunicar productos premium, novedades y ofertas. La integración entre catálogo, sitio web y tienda podría contribuir a fortalecer la experiencia y fidelización de este segmento de mayor valor.

Para los clientes de bajo consumo, las acciones comerciales podrían concentrarse principalmente en la tienda física y el sitio web, canales que representan conjuntamente aproximadamente el 89 % de sus compras. Estos medios podrían utilizarse para probar promociones orientadas a incrementar la frecuencia y el valor de compra, así como estrategias de venta cruzada utilizando categorías con mayor afinidad relativa, como los productos de oro y el vino.

Conclusiones

El objetivo del proyecto era identificar clientes con características y tendencias similares para agruparlos mediante técnicas de aprendizaje no supervisado y proponer estrategias de negocio basadas en los perfiles identificados. El algoritmo K-Means detectó a dos tipos de clientes principales, los de alto valor y los de bajo consumo, estos perfiles están principalmente diferenciados por sus ingresos, nivel de gasto, frecuencia de compra, cantidad de hijos y respuesta a campañas de ofertas.

Las propuestas principalmente se basan en el tipo de productos que compra cada tipo de cliente y el medio por el que compran; en resumen, se busca mantener a los clientes de alto valor con estrategias de retención y pertenencia, mientras que para los clientes de bajo consumo se busca maximizar el tipo de productos que ya compran e introducirlos a otros que pudieran interesarles.

En conjunto, el proyecto demuestra cómo la combinación de análisis exploratorio, técnicas de clustering, comparación de modelos y caracterización de segmentos puede transformar los datos históricos de clientes en información útil para apoyar decisiones comerciales y desarrollar estrategias de marketing más diferenciadas.